



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico II

Estudio comparativo de performance de implementaciones de una simulación de flujo de fluidos en C y en ASM x86-64 con procesamiento vectorial

8 de octubre de 2017

Organización del Computador II

Grupo: Ariane 5

Integrante	LU	Correo electrónico
Greco, Luis	150/15	luifergreco@gmail.com
Hertzulis, Nicolás	811/15	nicohertzulis@gmail.com
Ramos, Ricardo	841/11	riki_german@yahoo.com.ar



Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 +11) 4576-3300

<http://www.exactas.uba.ar>

Índice

1. Introducción	2
2. Desarrollo	2
2.1. Función solver_set_bnd	2
2.2. Función solver_lin_solve	3
2.3. Función solver_project	5
3. Resultados	7
3.1. Función solver_set_bnd	7
3.2. Función solver_lin_solve	8
3.3. Función solver_project	8
4. Conclusión	9

1. Introducción

En computación, un procesador vectorial es una unidad central de proceso que implementa un conjunto de instrucciones que operan sobre arreglos de una dimensión de tamaño fijo, llamados vectores, a diferencia de procesadores escalares, cuyas instrucciones operan únicamente sobre datos individuales.

Algunos programas informáticos pueden ser implementados en lenguaje ensamblador utilizando exclusivamente instrucciones escalares o utilizando también instrucciones vectoriales. Para estos programas el procesamiento vectorial constituye una optimización dado que se percibe un incremento en la performance (i.e. tiempo neto de procesamiento).

Por otro lado, los compiladores modernos de lenguajes de alto nivel, como GNU C Compiler (GCC) incluyen la posibilidad de realización de diversas optimizaciones que se aprecian en el código ensamblado, entre las que se encuentra la utilización de instrucciones de procesamiento vectorial cuando es posible.

Para el estudio comparativo utilizamos una simulación de flujo de fluidos basada en las ecuaciones de Navier-Stokes escrita en lenguaje C por el equipo docente de la materia. Hicimos una implementación alternativa de tres funciones involucradas en la simulación en lenguaje ensamblador x86-64 utilizando instrucciones de procesamiento vectorial. El estudio comparativo consiste en el estudio de la performance de las implementaciones en sendos lenguajes.

La presente investigación es importante porque a pesar de que la velocidad de procesamiento y la velocidad de acceso a memoria aumentan a lo largo de los años, la curva que describe el incremento de la primera tiene un mayor orden de magnitud que la curva de la segunda¹. Esto significa que la brecha es cada vez mayor y se traduce en un costo porcentual creciente de los accesos a memoria sobre el costo total de procesamiento de un programa.

Asimismo, esta investigación de carácter educativo es importante para programadores que se desempeñan en la academia o en la industria porque motiva a la optimización del código, a la medición de performance de los programas y a la profundización del conocimiento de lo que sucede en el procesador en la ejecución de programas escritos en lenguajes de alto nivel.

2. Desarrollo

El código fuente de la simulación está escrito en lenguaje C y el compilador utilizado es GCC. Para las funciones de *C solver_lin_solve*, *solver_set_bnd* y *solver_project* hicimos implementaciones alternativas escritas en el lenguaje ensamblador de la familia de procesadores Intel x86-64. Las instrucciones vectoriales en lenguaje ensamblador utilizan registros de 128 bits. Los estados de la simulación se representan mediante matrices de números decimales de punto flotante de precisión simple (32 bits). Los algoritmos asumen que todas las matrices en una ejecución particular constan de $n + 2$ filas y $n + 2$ columnas con $n \geq 4$ y n múltiplo de 4. A continuación se explica la implementación en ensamblador de las tres funciones.

2.1. Función *solver_set_bnd*

La función *solver_set_bnd* se encarga de actualizar los valores del borde. El algoritmo consta de tres partes: el procesamiento de los bordes horizontales (la primera y la última fila de la matriz), el procesamiento de los bordes verticales (la primera y la última columna) y el procesamiento de las esquinas. Los primeros dos se realizan en un ciclo.

¹<http://www.cs.columbia.edu/~sedwards/classes/2012/3827-spring/advanced-arch-2011.pdf>

El procesamiento horizontal consiste en sobrescribir respectivamente las celdas de las filas 0 y $n + 1$ con las filas 1 y n excluyendo la primera y la última celda de las filas. Si el valor del parámetro b es igual a 2 se cambia el signo del valor a escribir por su contrario, en otro caso se escribe el valor original. La lectura, escritura y cambio de signo se realizan de a 4 elementos con un registro vectorial, ya que las celdas de cada fila se encuentran contiguas en memoria.

El procesamiento vertical consiste en sobrescribir respectivamente las columnas 0 y $n + 1$ con las columnas 1 y n excluyendo la primera y la última celda de las columnas. Si el valor del parámetro b es igual a 1 se cambia el signo del valor a escribir por su contrario, en otro caso se escribe el valor original. El cambio de signo se realiza de a 4 elementos con un registro vectorial, pero la lectura y escritura se realizan individualmente porque las celdas no se encuentran contiguas en memoria.

El procesamiento de las esquinas consiste en sumar el valor de las dos celdas contiguas a cada esquina (contiguas en la interpretación matricial, no en memoria), luego dividir por dos ese valor y escribirlo en la esquina más cercana a esas celdas. La programación en lenguaje ensamblador implementa un procesamiento alternativo que produce el mismo resultado utilizando instrucciones de asignación (*mov*) y operaciones con enteros en lugar de la operación de punto flotante, que es más costosa y puede generar un error de redondeo. Consideraremos dos casos.

El primer caso se da cuando el parámetro b es igual a 1 o 2. Si b es 1 el signo de los valores de los bordes verticales es el opuesto al valor de las celdas de las columnas de origen pero los valores de los bordes horizontales mantienen el signo original. Si b es 2 se invierte el signo los bordes horizontales y se mantiene el signo de los bordes verticales. Por lo tanto, el proceso consiste en escribir cero en las cuatro esquinas, ya que los dos valores adyacentes a cada una son iguales en módulo y con signos opuestos.

El segundo caso se da cuando b tiene otro valor. El proceso consiste en sobrescribir cada esquina con el valor de cualquiera de las dos celdas adyacentes, ya que al no haber cambios de signo estas celdas tienen el mismo valor.

2.2. Función `solver_lin_solve`

El ciclo principal de la función está formado por dos ciclos: un ciclo que recorre las columnas de las matrices y otro ciclo que recorre las filas. A causa de que las matrices contienen dimensiones múltiplos de cuatro, sin contar con las filas y columnas borde que no se usan en esta función, y los elementos de las matrices ocupan 4 bytes hemos decidido fetchear, fetchear es cargar de memoria, de a cuatro elementos consecutivos de una fila para aprovechar el espacio de los registros *xmm*, que es de 16 bytes, y por lo tanto podemos cargar cuatro elementos en un solo fetch. Así el índice de las columnas, i , queda en un rango entre 1 y $N/4$, donde cada incremento de i representa avance de a cuatro columnas. El ciclo sobre columnas es el primero. Adentro tenemos otro ciclo donde se recorren las filas de a una.

Empezamos cargando desde matriz x . En cada iteración sobre fila se chequea si la fila es la primera, tal que si es así entonces se realiza 1er fetch de cuatro elementos consecutivos desde matriz x en un *xmm* llamado *xmm_piso*. Si no es la primera entonces se copian de un registro *xmm*, llamado *xmm_backup*, que contiene los cuatro resultados de ciclo anterior. Luego realizamos 2do fetch de a cuatro de una fila siguiente, en un *xmm* llamado *xmm_left* y avanzamos dos posiciones para un 3er fetch de a cuatro en un *xmm* llamado *xmm_right*. En la siguiente fila fetchearnos de a cuatro en un *xmm* llamado *xmm_techo*. Los elementos cargados desde x forman un bloque de elementos (ver figura 1 (a)) de donde vamos a obtener cuatro resultados a partir de seis accesos a memoria. Por otra parte de matriz x_0 fetchearnos cuatro elementos consecutivos en un *xmm*

llamado *xmm_x0*.

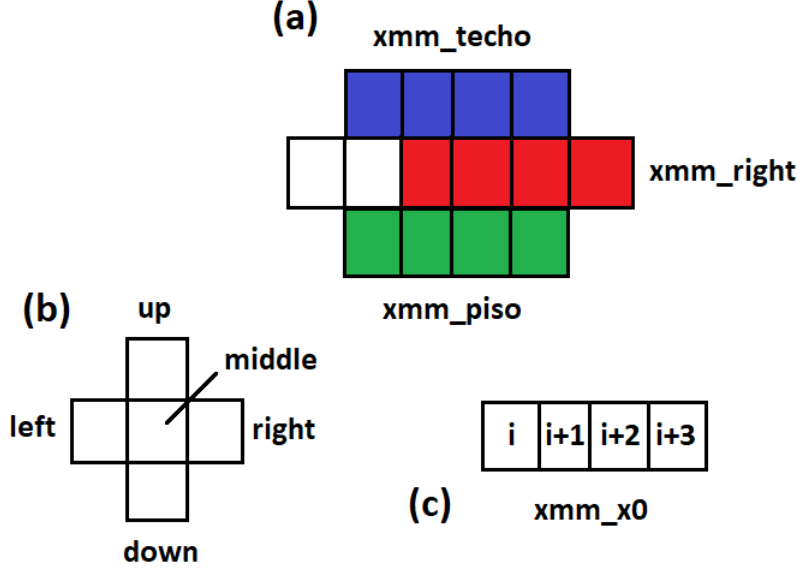


Figura 1: (a) Bloque de elementos de matriz x . (b) Sumandos de x en código c . (c) Empacado de elementos de x_0 .

Representamos en figura 1 (b) los sumandos de matriz x que aparecen en cuerpo de ciclo principal en código c (ver código *solver_lin_solve* en *solver.c*): *up* representa al sumando $x[IX(i, j + 1)]$, *down* a $x[IX(i, j - 1)]$, *left* a $x[IX(i - 1, j)]$ y *right* a $x[IX(i + 1, j)]$. Por último *middle* representa a sumando $x_0[IX(i, j)]$. En bloque de figura 1 (a) vemos que *xmm_techo* empaqueta a los cuatro sumandos *up*, *xmm_piso* empaqueta a los cuatro *down* y *xmm_right* empaqueta a los cuatro *right* de los cuatro puntos centrales del bloque. También vemos, en figura 1 (c), que *xmm_x0* empaqueta a los cuatro *middle* asociados a los puntos centrales del bloque. La idea que usamos para paralelizar cálculos es sumar los valores de los registros *xmm_piso*, *xmm_techo* y *xmm_right* en paralelo obteniendo cuatro sumas parciales. Luego completar la suma alrededor de un punto individualmente, a causa de dependencia de vecino izquierdo, sumando *up*, *down*, *left* y *right*, comenzando con entorno de primero de los cuatro puntos centrales. Terminar las operaciones sobre ese punto, usando primer *middle* empaquetado en *xmm_x0*, y pasar a operar sobre vecino derecho usando como sumando *left* de este al resultado obtenido. De esta forma se respeta el código c en donde sobre una fila de x los puntos se actualizan hacia derecha, es decir que dependen de sus vecinos izquierdos.

Volviendo al cuerpo del ciclo, una vez que tenemos los datos desempaquetamos con instrucción *cvtps2pd*, que convierte los *single* en parte baja de *xmm* fuente a *double* en *xmm* destino. Luego shifteamos a derecha con *psrldq* para acceder a los *single* de parte alta de los *xmm* y convertirlos a *double*. En este paso obtenemos *xmm_piso_low* y *xmm_piso_high* que corresponden a desempacar a *double* los 2 *single* en parte baja y los 2 *single* en parte alta de *xmm_piso* respectivamente. Repetimos este procedimiento con *xmm_right* obteniendo *xmm_right_low* y *xmm_right_high*. De misma manera desempaquetamos *xmm_techo* en *xmm_techo_low* y *xmm_techo_high*. Por otra parte se convierten los *singles* a y c a *double* en *xmm_a* y *xmm_b* con instrucción *cvts2sd*, que convierte *escalar single* de parte menos significativa de *xmm* fuente a *escalar double* en parte baja de *xmm* destino. Por último convertimos los *single* de *xmm_x0* usando instrucción *cvtps2pd* en *double* obteniendo dos *xmm*: *xmm_x0_low* y *xmm_x0_high*. También convertimos primer *single* en *xmm_left* a *double* con instrucción *cvts2sd* que convierte *single* de parte menos significativa

de *xmm* fuente a double en parte baja de *xmm* destino. Se guarda esto en *xmm_res*, que usaremos como contenedor de resultados finales.

Siguiente paso se suman los dos double de *xmm_techo_low* y *xmm_right_low* guardándose en un *xmm* temporal. Luego a estos dos doubles resultado de suma entre techo y lado derecho les sumamos los dos doubles en *xmm_piso_low* obteniendo sumas parciales $x[IX(i+1, j)] + x[IX(i, j-1)] + x[IX(i, j+1)]$ de entorno de dos puntos de *x*. Guardamos esto en *xmm* llamado *xmm_sum_parcial_low* y repetimos procedimiento con los *xmm* de partes altas: *xmm_techo_high*, *xmm_piso_high* y *xmm_right_high*. Guardamos estos resultados en *xmm_sum_parcial_high* asociados a otros dos puntos de *x*.

Paso siguiente entramos en ciclo que se repite cuatro veces operando sobre doubles de parte baja y obteniendo en cada iteración un resultado a guardar en matriz *x*. Primero se suman escalar de *xmm_res* con double en parte baja de alguno de los *xmm_sum_parcial* con instrucción *addsd* que suma escalares doubles, obteniéndose $x[IX(i-1, j)] + x[IX(i+1, j)] + x[IX(i, j-1)] + x[IX(i, j+1)]$, y guardándose en *xmm_res*. Entonces se multiplica con escalar *xmm_a* usando instrucción *mulsd*, que multiplica escalares double, obteniéndose $a * (x[IX(i-1, j)] + x[IX(i+1, j)] + x[IX(i, j-1)] + x[IX(i, j+1)])$ y lo guardamos en *xmm_res*. Luego le sumamos double en parte baja de *xmm_x0* obteniendo $x0[IX(i, j)] + a * (x[IX(i-1, j)] + x[IX(i+1, j)] + x[IX(i, j-1)] + x[IX(i, j+1)])$ y lo guardamos en *xmm_res*. Paso seguido dividimos *xmm_res* por escalar *xmm_c* con instrucción *divsd*, que divide escalares double, obteniendo $(x0[IX(i, j)] + a * (x[IX(i-1, j)] + x[IX(i+1, j)] + x[IX(i, j-1)] + x[IX(i, j+1)])) / c$ y lo guardamos en *xmm_res*. En primer iteración *xmm_res* contiene sumando left de 1er punto central de bloque en figura 1 y al sumar con escalar en parte baja de *xmm_sum_parcial_low* obtenemos suma de up, low, right y left para ese punto. Realizamos las operaciones restantes y guardamos este resultado en *xmm_res* para ser usado como sumando left en siguiente iteración. Finalmente convertimos el resultado en *xmm_res* de double a single con instrucción *cvtss2ss* y lo movemos a *xmm_backup* con instrucción *movss*, que mueve un escalar single a parte baja de *xmm* destino. Una vez guardado resultado en *xmm_backup* shifteamos este registro a izquierda con instrucción *pslldq*, que mueve a izquierda una double quadword, moviendo de a 4 bytes el valor recientemente cargado. De esta manera dejamos espacio para un single en parte baja de *xmm_backup* que recibirá a próximo resultado desde *xmm_res*. En cada iteración de este ciclo shifteamos los registros *xmm_sum_parcial_low* y *xmm_x0_low* a derecha, con *psrldq*, para acceder a las partes altas de estos y, en caso de haber usado los dos doubles de cada registro pasamos a operar con *xmm_sum_parcial_high* y *xmm_x0_high*.

Luego de salir de este ciclo de cuatro iteraciones tenemos en *xmm_backup* los cuatro resultados a subir en matriz *x* pero con las posiciones invertidas por como se cargaron en las iteraciones. Entonces intercambiamos sus posiciones con instrucción *pshufd* que reubica doublewords en destino con ayuda de un registro temporal. Una vez hecho esto guardamos estos cuatro resultados en matriz *x*, con instrucción *movups*, y saltamos a siguiente fila terminando una iteración de ciclo sobre filas. En próxima iteración no tenemos que cargar de memoria los cuatro resultados obtenidos, ya que los tenemos guardados en *xmm_backup*, que sobrescribieron fila de *x* y son requeridos. Al iterar sobre *N* filas terminamos una iteración de ciclo principal y avanzamos a las siguientes cuatro columnas de *x* y *x0*. Una vez iterado *N/4* veces ciclo principal salimos de este con bloque de $N \times N$ de *x* actualizado.

2.3. Función solver_project

El algoritmo con el que implementamos esta función se lleva adelante en varias etapas, por un lado los calculos que se hacen dentro del mismo algoritmo, y por otro, los que estan externalizados y llevados a cabo por las otras funciones que fueron implementadas en assembler en este trabajo.

Esta implementación sigue la linea del código de la misma función escrito en C, con dos ciclos y

llamadas a otras funciones. Como dentro de la función llamamos a `solver_lin_solve` y `solver_set_bnd` y estos terminan alterando los parametros que utilizamos, necesitamos hacer esos procesamientos en distintos momentos dentro de la ejecución y de ahí la necesidad de hacerlo en dos ciclos.

Los calculos que hacemos dentro de la función, trabajan sobre la matriz *div*, con las matrices *u* y *v* de `solver`. Para cada celda de la matriz *div*, vamos a operar con las celdas aledañas (por arriba y por abajo, no las que están en diagonal) a la de la misma posición de las matrices *u* y *v* (tengamos en cuenta que todas estas son matrices de igual dimensión). Notemos que solo podemos realizar estas operaciones en las celdas de la matriz que no se encuentran en los bordes de la misma. Entonces, vamos a querer hacer estas operaciones con instrucciones SIMD. El mayor problema acá se presentó cuando quisimos hacer las operaciones que tomaban las celdas de distintas filas de la matriz. Esto lo resolvimos teniendo 4 punteros, uno a cada celda *aledaña* con la que íbamos a operar, empezando por el primer elemento de nuestra submatriz. Es decir, para el (1,1) tenemos un puntero al (0,1), otro al (2,1), otro al (1,0) y otro al (1,2). Con esto podemos usar SIMD tomando de a 4 elementos, tanto en la matriz que vamos a modificar como en las otras con las que vamos a operar, donde ahora tenemos punteros a los elementos que nos interesan.

Cuando tomamos la matriz *div* (la "principal", o sobre la cual estamos operando), con una instrucción SIMD avanzamos de a 4 celdas. Como la submatriz en la que nos movemos tiene el tamaño de sus filas múltiplo de 4 (dato del enunciado), no tenemos que preocuparnos por tomar algún elemento no deseado cuando la función termine de recorrer una fila. Con lo que sí tenemos que tener cuidado es con cómo pasar de una fila a otra, por que en la estructura, entre una fila y otra de la submatriz en la que trabajamos tenemos 2 elementos. Para resolver esto, chequeamos con el tamaño de cada fila (dato) si la terminamos de recorrer. En caso de no haber terminado, seguimos operando sobre la misma fila, y en caso de haber terminado de recorrerla, lo que hacemos es sumar dos posiciones extras para la próxima iteración, saltandonos así los bordes de la matriz, que no queremos modificar ahora.

Ahora lo único que nos restaba hacer en cada ciclo era dejar en cero todas las celdas de la misma submatriz pero de *p* (o sea, la matriz *p* sin sus bordes). En nuestra implementación lo hicimos al principio del ciclo (aun que podríamos haberlo hecho en otro momento dentro del ciclo, al no utilizar la matriz *p* para nada más a lo largo de ese primer ciclo). Esta matriz la recorreremos en conjunto con las demás, al ser exactamente del mismo tamaño de las demás.

Con esto termina el primer ciclo de esta función. Ahora llamamos dos veces a `solver_set_bnd` para completar los bordes de la matriz, que no los había tocado anteriormente. La llamamos una vez con la matriz *div* y otra con la matriz *p*. Luego, llamamos a `solver_lin_solve`.

Como podemos observar, estas llamadas a otras funciones modifican los parametros con los que trabajamos. Ahora en el segundo ciclo, trabajamos sobre las matrices *u* y *v* de `solver` (ambas de tamaño $(N+1) \times (N+1)$), y al igual que en el ciclo anterior lo que hacemos es recorrer la submatriz de $N \times N$ formada por la matriz sin sus bordes. En este caso lo único que cambia respecto del ciclo anterior es que son otras operaciones las que hay que hacer pero no son muy distintas, dado que volvemos a usar esas celdas aledañas. Luego vamos a recorrer las matrices de manera análoga a como hicimos en el primer ciclo.

Por último, llamamos a `solver_set_bnd` dos veces como hicimos antes, pero en este caso con las matrices *u* y *v*.

3. Resultados

3.1. Función `solver_set_bnd`

Se evaluó el código en assembler, llamado ASM, y código C de la función `solver set bound` sobre seis tamaños distintos de matrices. Al variar parámetro b , valores de 1, 2, 3 y 10, se obtienen promedios similares en caso de matriz con tamaño 512x512 (ver tabla), sacando outliers. Los resultados se mantienen alrededor de 18500 ticks para ASM y 54000 ticks para C. Repetimos escenario con matriz de tamaño 16x16, variando b en mismos valores que para tamaño 512x512. Aunque se nota variación de tiempos entre mediciones (ver cuadro 1) no se nota gran cambio en los resultados, manteniéndose el promedio de tiempos C alrededor de 2000 ticks y tiempos ASM alrededor de 350 ticks.

	C	ASM
<i>solver_set_bnd_100_16_b1</i>	2061.989474	335.134021
<i>solver_set_bnd_100_16_b2</i>	2081.364583	360.896907
<i>solver_set_bnd_100_16_b3</i>	2068.020408	376.135417
<i>solver_set_bnd_100_512_b1</i>	56134.061856	18529.938144
<i>solver_set_bnd_100_512_b2</i>	54054.041667	19752.25000
<i>solver_set_bnd_100_512_b3</i>	54835.708333	18544.926316

Cuadro 1: Tabla de promedios ticks función `solver_set_bnd` para tamaños 16x16 y 512x512.

A causa de esto y de que no queremos llenar de gráficas innecesarias hemos decidido fijar el parámetro b en 2 para restantes experimentaciones de función. Se muestra en figura 2 promedio de ticks gastado en ejecución de los códigos, donde para cada tamaño los códigos se ejecutaron 100 veces.




Figura 2: Tiempos en ticks de ejecución de código C vs código ASM para función `solver_set_bnd`

Se ve que el código C gasta más tiempo que código ASM, agrandándose esta diferencia a medida que aumenta el tamaño de matriz.

3.2. Función solver_lin_solve

En este caso hemos variado los parámetros a, b y c para tamaños de matriz 16×16 y 512×512 . En la tabla siguiente se muestran los promedios obtenidos sobre datos sin outliers para valores de: $a = 1,0f$ y $c = 4,0f$, llamado *1erOp.a.y.c*, $a = 0,3f$ y $c = 2,8f$, llamado *2daOp.a.y.c*, y $a = -10,0f$, $c = 0,02f$, llamado *3raOp.a.y.c*. Los valores de b son: 1, 2, 3 y 10. En el caso de tamaño 16×16 obtenemos que el promedio de tiempos de ejecución sin outliers para código en C está alrededor de los 400000 ticks y para código ASM está alrededor de 300000 ticks. En el caso de tamaño 512×512 se obtiene que promedio de tiempos C está alrededor de $2,3 * e + 08$ y tiempos ASM está alrededor de $1,6 * e + 08$ ticks.

	C	ASM
<i>solver_lin_solve.b1.1erOp.a.y.c.16</i>	392938.224490	236550.530612
<i>solver_lin_solve.b2.1erOp.a.y.c.16</i>	442471.040816	252094.406250
<i>solver_lin_solve.b3.1erOp.a.y.c.16</i>	429083.391753	253708.344086
<i>solver_lin_solve.b10.1erOp.a.y.c.16</i>	436142.561224	261522.363636
<i>solver_lin_solve.b1.2daOp.a.y.c.16</i>	461250.443299	369954.084211
<i>solver_lin_solve.b10.2daOp.a.y.c.16</i>	430715.626263	352677.979592
<i>solver_lin_solve.b1.3raOp.a.y.c.16</i>	427202.773196	262558.585859
<i>solver_lin_solve.b10.3raOp.a.y.c.16</i>	429630.377551	237256.265306
<i>solver_lin_solve.b1.1raOp.a.y.c.512</i>	2.320231e+08	1.576663e+08
<i>solver_lin_solve.b2.1raOp.a.y.c.512</i>	2.364991e+08	1.582853e+08
<i>solver_lin_solve.b10.1raOp.a.y.c.512</i>	2.313464e+08	1.570360e+08
<i>solver_lin_solve.b1.3raOp.a.y.c.512</i>	2.343117e+08	1.585373e+08
<i>solver_lin_solve.b10.3raOp.a.y.c.512</i>	2.337076e+08	1.611139e+08

Cuadro 2: Tabla de promedios ticks función solver_lin_solve para tamaños 16×16 y 512×512 .

Se ve en la cuadro 2 que se repite una proporción de casi el doble de gasto temporal en ejecuciones C respecto a ejecuciones ASM. Entonces decidimos elegir parámetros de *1erOp.a.y.c*, $b = 2$ y las matrices *solver* $\rightarrow u$, *solver* $\rightarrow v$. Con estos parámetros variamos el tamaño de las matrices y graficamos los tiempos (ver figura 3). Se observa notable diferencia de gasto temporal, código C gasta más ticks que ASM.

3.3. Función solver_project

Hemos medido la función sobre cuatro matrices diferentes: *1erOp* que comienza con valor (0.1,0.2) en posición (0,0) y luego a medida que avanzamos en posiciones se incrementa en uno el valor en posición anterior y se asigna ese resultado, *2daOp* con mismo proceso pero comenzando en (0.09,-100), *3eraOp* comenzando en (-10,0.08) y *4taOp* comenzando en (1000,2000). Se evalúan matrices con tamaño 16×16 y 512×512 para observar si hay gran cambio en las proporciones de tiempo al ejecutar código. Se observa en cuadro 3 los resultados y se ve que para ambos tamaños el código C gasta alrededor de un tercio más que tiempo gastado por código ASM.

A causa de que al variar la matriz obtenemos resultados similares, alrededor de 380000 ticks en código C y alrededor de 270000 en asm para tamaño 16×16 (ver tabla), hemos decidido evaluar los códigos sobre matriz *1erOp*. En la gráfica se muestran los promedios para distintos tamaños (figura 4).

Observando la gráfica vemos que en este caso la diferencia de tiempos no es tan grande. Notamos que el código de la función hace repetidamente llamadas a las otras funciones: *solver_set_bnd* y




Figura 3: Tiempos en ticks de ejecución de código C vs código ASM para función `solver_lin_solve`

	C	SD(C)	ASM	SD(ASM)
<i>solver_project_1erOp_matrices_16</i>	384948.313131	36503.785424	271883.232323	28601.904704
<i>solver_project_2daOp_matrices_16</i>	385072.787879	34959.635332	271078.418367	15269.103250
<i>solver_project_3eraOp_matrices_16</i>	382180.464646	29999.207094	273869.231579	13431.150139
<i>solver_project_4taOp_matrices_16</i>	353107.683673	24055.789775	259020.680412	12374.032677
<i>solver_project_1erOp_matrices_512</i>	1.925452e+08	1.804747e+06	1.584625e+08	1.589767e+06
<i>solver_project_2daOp_matrices_512</i>	1.939796e+08	3.205834e+06	1.591681e+08	2.147394e+06
<i>solver_project_4taOp_matrices_512</i>	1.938470e+08	2.764452e+06	1.670031e+08	8.623912e+06

Cuadro 3: Tabla de promedios ticks función `solver_project` para tamaños 16x16 y 512x512. SD es desvío estandar.

`solver_lin_solve`. Se ve que a medida que el tamaño de matriz aumenta las curvas que representan los gastos de tiempo tienden a separarse.

4. Conclusión

La primera problemática encontrada fue identificar en qué casos se puede paralelizar el procesamiento y en cuáles no. Notamos que solo es posible utilizar instrucciones vectoriales cuando los datos están ubicados en forma contigua en memoria. Dada una matriz de datos cuyas filas se encuentran almacenadas en forma secuencial y contigua en memoria, se puede paralelizar el proceso si recorremos la matriz en forma horizontal (i.e. fila a fila) pero no en forma vertical (i.e. columna a columna).

En la función `solver_lin_solve` la paralelización de los cálculos implicó realizar las operaciones matemáticas en distinto orden y esto trajo aparejada una diferencia en los resultados de ambas implementaciones, debida al redondeo propio de la representación numérica de punto flotante. Consideremos cuatro matrices del mismo tamaño: dos matrices p_{ASM} y p_C inicializadas con los mismos valores y otras dos matrices div_{ASM} y div_C también inicializadas con los mismos valores.




Figura 4: Tiempos en ticks de ejecución de código C vs código ASM para función `solver_project`

Luego apliquemos la implementación en C de `solver_lin_solve` a las matrices con subíndice C y la implementación en ensamblador a las matrices con subíndice ASM. El módulo de la diferencia de cada uno de los valores finales de las matrices p y div fue siempre menor que 10^{-4} en las pruebas realizadas. La conversión de los valores numéricos expresados en punto flotante de precisión simple a precisión doble antes de realizar las operaciones matemáticas no aportó una reducción visible de esta diferencia.

Notamos que la utilización de registros vectoriales permite reducir drásticamente la cantidad de accesos a memoria necesarios, lo cual, como vimos en la introducción, tiene un impacto serio en la performance de los programas. Por ejemplo, en la implementación en lenguaje ensamblador de `solver_lin_solve` logramos reducir los accesos a memoria a cinco por cada cuatro celdas procesadas. Suponemos que la implementación en lenguaje C hace más accesos a memoria mirando la programación.

En un análisis de los gráficos de resultados, se puede observar que, a pesar de la variación del tamaño de las entradas, la proporción de ciclos de reloj se mantiene constante entre las implementaciones de C y ensamblador, siendo siempre menor la medición de las implementaciones en ensamblador.

En la función `solver_set_bnd` se observó gran diferencia en gastos temporales, la implementación C gastó alrededor de cinco veces el tiempo gastado por la implementación en ASM.

En la función `solver_lin_solve` se observó marcada diferencia en tiempo de ejecución, código C gastó alrededor del doble de tiempo que código ASM. Suponemos que la llamada a otra función influencia en la disminución de diferencia de tiempos, menor diferencia comparada a lo obtenido en función `solver_set_bnd`.

En la función `solver_project` se observó poca diferencia en tiempos de ejecución, implementación C gastó alrededor de un tercio de tiempo que código ASM.