

# Trabajo Práctico II

Estudio comparativo de performance de implementaciones de una simulación de flujo de fluidos en C y en ASM x86-64 con procesamiento vectorial

4 de octubre de 2017

Organización del Computador II

Grupo: Ariane 5

Integrante	LU	Correo electrónico
Greco, Luis	150/15	luifergreco@gmail.com
Hertzulis, Nicolás	811/15	nicohertzulis@gmail.com
Ramos, Ricardo	841/11	riki_german@yahoo.com.ar



## Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja) Intendente Güiraldes 2610 - C1428EGA Ciudad Autónoma de Buenos Aires - Rep. Argentina

$$\label{eq:fax: problem} \begin{split} \text{Tel/Fax: (++54 +11) } & 4576\text{-}3300 \\ \text{http://www.exactas.uba.ar} \end{split}$$

# ${\rm \acute{I}ndice}$

1.	Introducción	2
	Desarrollo       2.1. Función solver_lin_solve	4
3.	Resultados 3.1. Eficiencia c vs paralelismo simd asm	<b>5</b>
4.	Conclusión	6

## 1. Introducción

En computación, un procesador vectorial es una unidad central de proceso que implementa un conjunto de instrucciones que operan sobre arreglos de una dimensión de tamaño fijo, llamados vectores, a diferencia de procesadores escalares, cuyas instrucciones operan únicamente sobre datos individuales.

Algunos programas informáticos pueden ser implementados en lenguaje ensamblador utilizando exclusivamente instrucciones escalares o utilizando también instrucciones vectoriales. Para estos programas el procesamiento vectorial constituye una optimización dado que se percibe un incremento en la performance (i.e. tiempo neto de procesamiento).

Por otro lado, los compiladores modernos de lenguajes de alto nivel, como GNU C Compiler (GCC) incluyen la posibilidad de realización de diversas optimizaciones que se aprecian en el código ensamblado, entre las que se encuentra la utilización de instrucciones de procesamiento vectorial cuando es posible.

Para el estudio comparativo utilizamos una simulación de flujo de fluidos basada en las ecuaciones de Navier-Stokes escrita en lenguaje C por el equipo docente de la materia. Hicimos una implementación alternativa de tres funciones involucradas en la simulación en lenguaje ensamblador x86-64 utilizando instrucciones de procesamiento vectorial. El estudio comparativo consiste en el estudio de la performance de las implementaciones en sendos lenguajes.

La presente investigación es importante porque a pesar de que la velocidad de procesamiento y la velocidad de acceso a memoria aumentan a lo largo de los años, la curva que describe el incremento de la primera tiene un mayor orden de magnitud que la curva de la segunda. Esto significa que la brecha es cada vez mayor y se traduce en un costo porcentual creciente de los accesos a memoria sobre el costo total de procesamiento de un programa.

Asimismo, esta investigación de caracter educativo es importante para programadores que se desempeñan en la academia o en la industria porque motiva a la optimización del código, a la medición de performance de los programas y a la profundización del conocimiento de lo que sucede en el procesador en la ejecución de programas escritos en lenguajes de alto nivel.

## 2. Desarrollo

El código fuente de la simulación está escrito en lenguaje C y el compilador utilizado es GCC. Para las funciones de C solver\_lin\_solve, solver\_set\_bnd y solver\_project hicimos implementaciones alternativas escritas en el lenguaje ensamblador de la familia de procesadores Intel x86-64. Las instrucciones vectoriales en lenguaje ensamblador utilizan registros de 128 bits. Los estados de la simulación se representan mediante matrices de números decimales de punto flotante de precisión simple (32 bits). Los algoritmos asumen que todas las matrices en una ejecución particular constan de n+2 filas y n+2 columnas con  $n\geq 4$  y n múltiplo de 4. A continuación se explica la implementación en ensamblador de las tres funciones.

#### 2.1. Función solver\_lin\_solve

El ciclo principal de la función está formado por dos ciclos: un ciclo que recorre las columnas de las matrices y otro ciclo que recorre las filas. A causa de que las matrices contienen dimensiones múltiplos de cuatro, sin contar con las filas y columnas borde que no se usan en esta función, y los elementos de las matrices ocupan 4 bytes hemos decidido fetchear, fetchear es cargar de memoria, de a cuatro elementos consecutivos de una fila para aprovechar el espacio de los registros xmm, que es de 16 bytes, y por lo tanto podemos cargar cuatro elementos en un solo fetch. Así el índice de las columnas, i, queda en un rango entre 1 y N/4, donde cada incremento de i representa avance de a cuatro columnas. El ciclo sobre columnas es el primero. Adentro tenemos otro ciclo donde se recorren las filas de a una.

Empezamos cargando desde matriz x. En cada iteración sobre fila se chequea si la fila es la primera, tal que si es así entonces se realiza 1er fetch de cuatro elementos consecutivos desde matriz

x en un xmm llamado xmm-piso. Si no es la primera entonces se copian de un registro xmm, llamado xmm-backup, que contiene los cuatro resultados de ciclo anterior. Luego realizamos 2do fetch de a cuatro de una fila siguiente, en un xmm llamado xmm-left y avanzamos dos posiciones para un 3er fetch de a cuatro en un xmm llamado xmm-right. En la siguiente fila fetcheamos de a cuatro en un xmm llamado xmm-techo. Los elementos cargados desde x forman un bloque de elementos (ver figura 1 (a)) de donde vamos a obtener cuatro resultados a partir de seis accesos a memoria. Por otra parte de matriz x0 fetcheamos cuatro elementos consecutivos en un xmm-x0.

Representamos en figura 1 (c) los sumandos de matriz x que aparecen en cuerpo de ciclo principal en código c (figura 2): up representa al sumando x[IX(i,j+1)], down a x[IX(i,j-1)], left a x[IX(i-1,j) y right a x[IX(i+1,j)]. Por último middle representa a sumando x0[IX(i,j)]. En bloque de figura 1 (a) vemos que  $xmm\_techo$  empaca a los cuatro sumandos up,  $xmm\_piso$  empaca a los cuatro down y  $xmm\_right$  empaca a los cuatro right de los cuatro puntos centrales del bloque. También vemos, en figura 1 (b), que  $xmm\_x0$  empaca a los cuatro middle asociados a los puntos centrales del bloque. La idea que usamos para paralelizar cálculos es sumar los valores de los registros  $xmm\_piso$ ,  $xmm\_techo$  y  $xmm\_right$  en paralelo obteniendo cuatro sumas parciales. Luego completar la suma alrededor de un punto individualmente, a causa de dependencia de vecino izquierdo, sumando up, down, left y right, comenzando con entorno de primero de los cuatro puntos centrales. Terminar las operaciones sobre ese punto, usando primer middle empaquetado en  $xmm\_x0$ , y pasar a operar sobre vecino derecho usando como sumando left de este al resultado obtenido. De esta forma se respeta el código c en donde sobre una fila de c los puntos se actualizan hacia derecha, es decir que dependen de sus vecinos izquierdos.

Volviendo al cuerpo del ciclo, una vez que tenemos los datos desempaquetamos con instrucción cvtps2pd, que convierte los single en parte baja de xmm fuente a double en xmm destino. Luego shifteamos a derecha con psrldq para acceder a los single de parte alta de los xmm y convertirlos a double. En este paso obtenemos  $xmm\_piso\_low$  y  $xmm\_piso\_high$  que corresponden a desempacar a double los 2 single en parte baja y los 2 single en parte alta de  $xmm\_piso$  respectivamente. Repetimos este procedimiento con  $xmm\_right$  obteniendo  $xmm\_right\_low$  y  $xmm\_right\_high$ . De misma manera desempaquetamos  $xmm\_techo$  en  $xmm\_techo\_low$  y  $xmm\_techo\_high$ . Por otra parte se convierten los singles a y c a double en  $xmm\_a$  y  $xmm\_b$  con instrucción cvtss2sd, que convierte escalar single de parte menos significativa de xmm fuente a escalar double en parte baja de xmm destino. Por último convertimos los single de  $xmm\_x0$  usando instrucción cvtps2pd en double obteniendo dos xmm:  $xmm\_x0\_low$  y  $xmm\_x0\_high$ . También convertimos primer single en  $xmm\_left$  a double con instrucción cvtss2sd que convierte single de parte menos significativa de xmm fuente a double en parte baja de xmm destino. Se guarda esto en  $xmm\_res$ , que usaremos como contenedor de resultados finales.

Siguiente paso se suman los dos double de  $xmm\_techo\_low$  y  $xmm\_right\_low$  guardándose en un xmm temporal. Luego a estos dos doubles resultado de suma entre techo y lado derecho les sumamos los dos doubles en  $xmm\_piso\_low$  obteniendo sumas parciales x[IX(i+1,j)] + x[IX(i,j-1)] + x[IX(i,j+1)] de entorno de dos puntos de x. Guardamos esto en xmm llamado  $xmm\_sum\_parcial\_low$  y repetimos procedimiento con los xmm de partes altas:  $xmm\_techo\_high$ ,  $xmm\_piso\_high$  y  $xmm\_right\_high$ . Guardamos estos resultados en  $xmm\_sum\_parcial\_high$  asociados a otros dos puntos de x.

Paso siguiente entramos en ciclo que se repite cuatro veces operando sobre doubles de parte baja y obteniendo en cada iteración un resultado a guardar en matriz x. Primero se suman escalar de  $xmm\_res$  con double en parte baja de alguno de los  $xmm\_sum\_parcial$  con instrucción addsd que suma escalares doubles, obteniéndose x[IX(i-1,j)]+x[IX(i+1,j)]+x[IX(i,j-1)]+x[IX(i,j+1)], y guardándose en  $xmm\_res$ . Entonces se multiplica con escalar  $xmm\_a$  usando instrucción mulsd, que multiplica escalares double, obteniéndose a\*(x[IX(i-1,j)]+x[IX(i+1,j)]+x[IX(i,j-1)]+x[IX(i,j-1)]+x[IX(i,j+1)]) y lo guardamos en  $xmm\_res$ . Luego le sumamos double en parte baja de  $xmm\_x0$  obteniendo x0[IX(i,j)]+a\*(x[IX(i-1,j)]+x[IX(i+1,j)]+x[IX(i,j-1)]+x[IX(i,j+1)]) y lo guardamos en  $xmm\_res$ . Paso seguido dividimos  $xmm\_res$  por escalar  $xmm\_c$  con instrucción divsd, que divide escalares double, obteniendo (x0[IX(i,j)]+a\*(x[IX(i-1,j)]+x[IX(i+1,j)]+x[IX(i+1,j)]+x[IX(i+1,j)]+x[IX(i,j+1)])/c y lo guardamos en  $xmm\_res$ . En primer iteración  $xmm\_res$ 

contiene sumando left de 1er punto central de bloque en figura 1 y al sumar con escalar en parte baja de xmm\_sum\_parcial\_low obtenemos suma de up, low, right y left para ese punto. Realizamos las operaciones restantes y guardamos este resultado en xmm\_res para ser usado como sumando left en siguiente iteración. Finalmente convertimos el resultado en xmm\_res de double a single con instrucción cvtsd2ss y lo movemos a xmm\_backup con instrucción movss, que mueve un escalar single a parte baja de xmm destino. Una vez guardado resultado en xmm\_backup shifteamos este registro a izquierda con instrucción pslldq, que mueve a izquierda una double quadword, moviendo de a 4 bytes el valor recientemente cargado. De esta manera dejamos espacio para un single en parte baja de xmm\_backup que recibirá a próximo resultado desde xmm\_res. En cada iteración de este ciclo shifteamos los registros xmm\_sum\_parcial\_low y xmm\_x0\_low a derecha, con psrldq, para acceder a las partes altas de estos y, en caso de haber usado los dos doubles de cada registro pasamos a operar con xmm\_sum\_parcial\_high y xmm\_x0\_high.

Luego de salir de este ciclo de cuatro iteraciones tenemos en  $xmm\_backup$  los cuatro resultados a subir en matriz x pero con las posiciones invertidas por como se cargaron en las iteraciones. Entonces intercambiamos sus posiciones con instrucción pshufd que reubica doublewords en destino con ayuda de un registro temporal. Una vez hecho esto guardamos estos cuatro resultados en matriz x, con instrucción movups, y saltamos a siguiente fila terminando una iteración de ciclo sobre filas. En próxima iteración no tenemos que cargar de memoria los cuatro resultados obtenidos, ya que los tenemos guardados en  $xmm\_backup$ , que sobreescribieron fila de x y son requeridos. Al iterar sobre N filas terminamos una iteración de ciclo principal y avanzamos a las siguientes cuatro columnas de x y x0. Una vez iterado N/4 veces ciclo principal salimos de este con bloque de  $N \times N$  de x actualizado.

#### 2.2. Función solver\_set\_bnd

La función solver\_set\_bnd se encarga de actualizar los valores del borde.

El algoritmo consta de tres partes: el procesamiento de los bordes horizontales (la primera y la última fila de la matriz), el procesamiento de los bordes verticales (la primera y la última columa) y el procesamiento de las esquinas. Los primeros dos se realizan en un ciclo.

El procesamiento horizontal consiste en sobreescribir las celdas de las filas 0 y n+1 con las filas 1 y n respectivamente. En algunos casos el valor de la celda se invierte antes de la escritura, según los datos de entrada (para más información consulte el código fuente). La lectura, escritura y cambio de signo se realiza de a 4 elementos con un registro vectorial, ya que las celdas de cada fila se encuentran contiguas en memoria. El procesamiento excluye a la primera y última celda de las filas involucradas.

El procesamiento vertical es similar al horizontal porque también consiste en sobreescribir respectivamente las columnas 0 y n+1 con las columnas 1 y n excluyendo la primera y la última celda de las columnas. Como sucede en el procesamiento de las filas, en algunos casos el valor de la celda se invierte antes de la escritura, según los datos de entrada. La diferencia es que solo el cambio de signo se realiza de a 4 elementos con un registro vectorial; la lectura y escritura se realizan individualmente porque las celdas no se encuentran contiguas en memoria.

El procesamiento de las esquinas consiste en sumar el valor de las dos celdas contiguas a cada esquina (contiguas en la interpretación matricial, no en memoria), luego dividir por dos ese valor y escribirlo en la esquina más cercana a esas celdas. El resultado de este cálculo está determinado por la operación realizada anteriormente sobre las filas y columnas, por lo tanto podemos evitar los cálculos en pos de una mayor performance si consideramos dos casos, a saber: si hubo o no cambios de signo. El cambio de signo, como ya fue mencionado anteriormente, está determinado por los parámetros de entrada.

El primer caso se da cuando hay cambio de signo de algunos valores. El cambio de signo respeta la siguiente regla: si el signo de cada elemento de las filas fue cambiado, entonces el signo de cada celda de las columnas no cambió, y viceversa. En este caso el resultado de la cuenta da siempre cero, por lo cual el proceso consiste en la escritura de este valor en las cuatro esquinas.

En el segundo caso no hay cambio de signo de ninguna celda. En este caso las esquinas serán sobreescritas con el valor de cualquiera de las dos celdas contiguas nodiagonales a ella, ya que

ambas tendrán el mismo valor (y el resultado de la cuenta es este valor).

## 2.3. Función solver\_project

Lorem ipsum dolor sit amet.

## 3. Resultados

Resultados: Deberán analizar y comparar las implementaciones de las funciones en su versión de la cátedra en C y la suya en assembler y mostrar los resultados obtenidos a través de tablas y gráficos. Para esto deberán plantear experimentos que les permitan medir el rendimiento y comparar entre las implementaciones. Deberán además explicar detalladamente los resultados obtenidos y analizarlos. En el caso de encontrar anomalías o comportamientos no esperados deberán construir nuevos experimentos para entender qué es lo que sucede.

# 3.1. Eficiencia c vs paralelismo simd asm

- función solver set b<br/>nd: se evaluó el código en assembler, llamado asm, y código c<br/> de la función solver set bound sobre seis tamaños distintos de matrices. al variar parámetro b<br/>, valores de 1,2,3 y 10, se obtienen promedios similares en caso de matriz con tamaño 512x512 (ver tabla), sacando outliers. los resultados se mantienen alrededor de 18500 ticks para asm y 54000 ticks para c. repetimos escenario con matriz de tamaño 16x16, variando b en mismos valores que para tamaño 512x512. aunque se nota variación de tiempos entre mediciones no se nota gran cambio en los resultados, manteniendose el promedio de tiempos c alrededor de 2000 ticks y tiempos asm alrededor de 350 ticks. a causa de esto y de que no queremos llenar de gráficas innecesarias hemos decidido fijar el parámetro b en 2 para restantes experimentaciones de función. se muestra en figura gráfica de ejecución de los códigos, donde para cada tamaño se ejecutaron 100 veces.

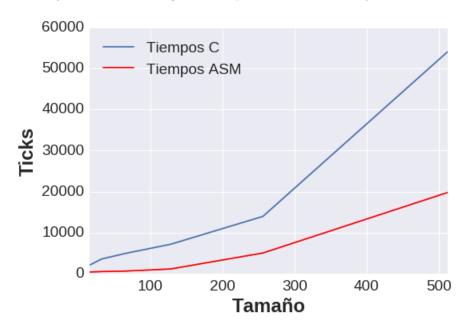


Figura 1: Tiempos en ticks de ejecución de código C vs código ASM

# 4. Conclusión

Conclusión: Reflexión final sobre los alcances del trabajo práctico, la programación vectorial a bajo nivel, problemáticas encontradas, y todo lo que consideren pertinente.